

Inżynieria danych

Wykład 13: optymalizacja zapytań

Katarzyna Grygiel

Semestr letni 2025/2026

Plan na plan

System zarządzania bazą danych przetwarza zapytania SQL na wykonywalny kod według następującego schematu:

1. zapytanie SQL

Plan na plan

System zarządzania bazą danych przetwarza zapytania SQL na wykonywalny kod według następującego schematu:

1. zapytanie SQL
↓ tłumaczenie kanoniczne
2. wyrażenie algebry relacyjnej

Plan na plan

System zarządzania bazą danych przetwarza zapytania SQL na wykonywalny kod według następującego schematu:

1. zapytanie SQL
↓ tłumaczenie kanoniczne
2. wyrażenie algebry relacyjnej
↓ optymalizacja heurystyczna
3. wyrażenie po zmianach

Plan na plan

System zarządzania bazą danych przetwarza zapytania SQL na wykonywalny kod według następującego schematu:

1. zapytanie SQL
↓ tłumaczenie kanoniczne
2. wyrażenie algebry relacyjnej
↓ optymalizacja heurystyczna
3. wyrażenie po zmianach
↓ optymalizacja na podstawie kosztu
4. plan fizyczny

Plan na plan

System zarządzania bazą danych przetwarza zapytania SQL na wykonywalny kod według następującego schematu:

1. zapytanie SQL
↓ tłumaczenie kanoniczne
2. wyrażenie algebry relacyjnej
↓ optymalizacja heurystyczna
3. wyrażenie po zmianach
↓ optymalizacja na podstawie kosztu
4. plan fizyczny
↓ dodanie instrukcji wykonania operatorów
5. wykonywalny kod

Plan na plan


System zarządzania bazą danych przetwarza zapytania SQL na wykonywalny kod według następującego schematu:

1. zapytanie SQL
↓ tłumaczenie kanoniczne
2. wyrażenie algebry relacyjnej
↓ optymalizacja heurystyczna
3. wyrażenie po zmianach
↓ optymalizacja na podstawie kosztu
4. plan fizyczny
↓ dodanie instrukcji wykonania operatorów
5. wykonywalny kod


Wszystkie powyższe transformacje odbywają się niezależnie od użytkownika – całością zarządza SZBD.

Tłumaczenie kanoniczne

```
SELECT  A2, A8, ..., An,  
        f(A7) AS x  
FROM    R1, R2, ..., Rm  
WHERE   P  
GROUP BY A1, ..., An  
HAVING  Q;
```




Który plan wybrać?




studenci(stud_id, nazwisko, instytut)
oceny(stud_id, kurs_id, ocena)
kursy(kurs_id, nazwa, ects, rok)

```
SELECT nazwisko, nazwa  
FROM studenci, oceny, kursy  
WHERE instytut = IA;
```

Który plan wybrać?




studenci(stud_id, nazwisko, instytut)
oceny(stud_id, kurs_id, ocena)
kursy(kurs_id, nazwa, ects, rok)



```
SELECT nazwisko, nazwa  
FROM studenci, oceny, kursy  
WHERE instytut = IA;
```

Plan z instrukcjami



Optymalizacja heurystyczna

Optymalizacja heurystyczna polega na iteracyjnym zastosowaniu reguł przepisывania dla wyrażenia z planu kanonicznego w celu uzyskania lepszego planu logicznego.

Optymalizacja heurystyczna

Optymalizacja heurystyczna polega na iteracyjnym zastosowaniu reguł przepisywania dla wyrażenia z planu kanonicznego w celu uzyskania lepszego planu logicznego.

Transformacje dokonywane na wyrażeniu algebry relacyjnej nie mogą nigdy doprowadzić do wyrażenia, którego realizacja skutkowałaby wynikiem innym niż realizacja początkowego wyrażenia.

Optymalizacja heurystyczna

Optymalizacja heurystyczna polega na iteracyjnym zastosowaniu reguł przepisywania dla wyrażenia z planu kanonicznego w celu uzyskania lepszego planu logicznego.

Transformacje dokonywane na wyrażeniu algebry relacyjnej nie mogą nigdy doprowadzić do wyrażenia, którego realizacja skutkowałaby wynikiem innym niż realizacja początkowego wyrażenia.

Takie przekształcenia można stosować do momentu, gdy nie będzie możliwe żadne dalsze uproszczenie. Aby jednak zapewnić, że reguły przepisywania nie będą stosowane zbyt długo (potencjalnie w nieskończoność), można ustalić warunek stopu (np. maksymalna liczba przepisania, maksymalny koszt optymalizacji na tym etapie, wykrywanie zapętlenia).

Reguła nr 1: rozdzielanie koniunkcji


$$\sigma_{p \wedge q}(R) = \sigma_p(\sigma_q(R))$$

```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
      AND nazwa = 'ID'
      AND o.stud_id = s.stud_id
      AND k.kurs_id = o.kurs_id;
```

Reguła nr 1: rozdzielanie koniunkcji

$$\sigma_{p \wedge q}(R) = \sigma_p(\sigma_q(R))$$


```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
      AND nazwa = 'ID'
      AND o.stud_id = s.stud_id
      AND k.kurs_id = o.kurs_id;
```



Reguła nr 1: rozdzielanie koniunkcji

$$\sigma_{p \wedge q}(R) = \sigma_p(\sigma_q(R))$$

```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
      AND nazwa = 'ID'
      AND o.stud_id = s.stud_id
      AND k.kurs_id = o.kurs_id;
```



Reguła nr 2: przesuwanie selekcji w dół


$$\sigma_p(R \times Q) \stackrel{*}{=} R \times \sigma_p(Q)$$

```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
       AND nazwa = 'ID'
       AND o.stud_id = s.stud_id
       AND k.kurs_id = o.kurs_id;
```

Reguła nr 2: przesuwanie selekcji w dół

$$\sigma_p(R \times Q) \stackrel{*}{=} R \times \sigma_p(Q)$$


```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
       AND nazwa = 'ID'
       AND o.stud_id = s.stud_id
       AND k.kurs_id = o.kurs_id;
```



Reguła nr 2: przesuwanie selekcji w dół

$$\sigma_p(R \times Q) \stackrel{*}{=} R \times \sigma_p(Q)$$

```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
       AND nazwa = 'ID'
       AND o.stud_id = s.stud_id
       AND k.kurs_id = o.kurs_id;
```



Reguła nr 3: zamiana $\times$ na $\bowtie$


$$\sigma_{R.x=Q.y}(R \times Q) = R \bowtie_{R.x=Q.y} Q$$

```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
       AND nazwa = 'ID'
       AND o.stud_id = s.stud_id
       AND k.kurs_id = o.kurs_id;
```

Reguła nr 3: zamiana $\times$ na $\bowtie$

$$\sigma_{R.x=Q.y}(R \times Q) = R \bowtie_{R.x=Q.y} Q$$


```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
      AND nazwa = 'ID'
      AND o.stud_id = s.stud_id
      AND k.kurs_id = o.kurs_id;
```



Reguła nr 3: zamiana $\times$ na $\bowtie$

$$\sigma_{R.x=Q.y}(R \times Q) = R \bowtie_{R.x=Q.y} Q$$

```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
      AND nazwa = 'ID'
      AND o.stud_id = s.stud_id
      AND k.kurs_id = o.kurs_id;
```



Reguła nr 4: przesuwanie projekcji w dół


$$\pi_{R.x, Q.y}(R \bowtie_{R.id=Q.id} Q) = \pi_{R.x, Q.y}(\pi_{x,id}(R) \bowtie \pi_{y,id}(Q))$$

```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
       AND nazwa = 'ID'
       AND o.stud_id = s.stud_id
       AND k.kurs_id = o.kurs_id;
```


Reguła nr 4: przesuwanie projekcji w dół

$$\pi_{R.x, Q.y}(R \bowtie_{R.id=Q.id} Q) = \pi_{R.x, Q.y}(\pi_{x,id}(R) \bowtie \pi_{y,id}(Q))$$


```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
      AND nazwa = 'ID'
      AND o.stud_id = s.stud_id
      AND k.kurs_id = o.kurs_id;
```



Reguła nr 4: przesuwanie projekcji w dół

$$\pi_{R.x, Q.y}(R \bowtie_{R.id=Q.id} Q) = \pi_{R.x, Q.y}(\pi_{x,id}(R) \bowtie \pi_{y,id}(Q))$$

```
SELECT nazwisko, nazwa
FROM   studenci s,
       oceny o,
       kursy k
WHERE  ocena > 3
      AND nazwa = 'ID'
      AND o.stud_id = s.stud_id
      AND k.kurs_id = o.kurs_id;
```



Podsumowanie najważniejszych reguł

- Wykonuj operację selekcji tak wcześnie, jak to możliwe: selekcja zmniejsza rozmiar relacji.

Podsumowanie najważniejszych reguł

- Wykonuj operację selekcji tak wcześnie, jak to możliwe: selekcja zmniejsza rozmiar relacji.
- Jeżeli po iloczynie kartezjańskim występuje selekcja, to zastąp obie te operacje przez θ -złączenie.

Podsumowanie najważniejszych reguł

- Wykonuj operację selekcji tak wcześnie, jak to możliwe: selekcja zmniejsza rozmiar relacji.
- Jeżeli po iloczynie kartezjańskim występuje selekcja, to zastąp obie te operacje przez θ -złączenie.
- Zastosuj łączność selekcji tak, aby możliwie wcześnie wykonać najbardziej restrykcyjną operację selekcji.

Podsumowanie najważniejszych reguł

- Wykonuj operację selekcji tak wcześnie, jak to możliwe: selekcja zmniejsza rozmiar relacji.
- Jeżeli po iloczynie kartezjańskim występuje selekcja, to zastąp obie te operacje przez θ -złączenie.
- Zastosuj łączność selekcji tak, aby możliwie wcześnie wykonać najbardziej restrykcyjną operację selekcji.
- Wykonuj operację rzutowania tak wcześnie, jak to możliwe: rzutowanie zmniejsza rozmiar relacji.

Podsumowanie najważniejszych reguł

- Wykonuj operację selekcji tak wcześnie, jak to możliwe: selekcja zmniejsza rozmiar relacji.
- Jeżeli po iloczynie kartezjańskim występuje selekcja, to zastąp obie te operacje przez θ -złączenie.
- Zastosuj łączność selekcji tak, aby możliwie wcześnie wykonać najbardziej restrykcyjną operację selekcji.
- Wykonuj operację rzutowania tak wcześnie, jak to możliwe: rzutowanie zmniejsza rozmiar relacji.
- Każdą operację wykonuj tylko raz: jeśli jakieś wyrażenie pojawia się w drzewie zapytania kilkakrotnie, po pierwszym wykonaniu przechowuj jego wynik.

Optymalizacja oparta na podstawie kosztów

Druga faza optymalizacji polega na analizie kosztów planów zapytania.

Na etapie optymalizacji kosztowej wybierany jest plan o najmniejszym koszcie spośród wszystkich możliwych planów. Najczęściej optymalizator ogranicza się do pewnego podzbioru potencjalnych planów.

Optymalizacja oparta na podstawie kosztów

Druga faza optymalizacji polega na analizie kosztów planów zapytania.

Na etapie optymalizacji kosztowej wybierany jest plan o najmniejszym koszcie spośród wszystkich możliwych planów. Najczęściej optymalizator ogranicza się do pewnego podzbioru potencjalnych planów.

W celu oszacowania kosztów wykonania planu obliczamy:

- szacunkowy koszt wykonania każdego operatora (zależy od rozmiarów argumentów wejściowych),
- szacunkowy rozmiar wyniku wykonania każdego operatora.

Aby umożliwić powyższe działania, system bazodanowy przechowuje statystyki dotyczące relacji i ich atrybutów.

Statystyki

Statystyki dotyczące każdej relacji bazowej R :

- liczba krotek relacji (moc relacji R),
- liczba krotek w jednym bloku (pojemność bloku),
- liczba bloków potrzebnych do zapisania relacji R .

Statystyki

Statystyki dotyczące każdej relacji bazowej R :

- liczba krotek relacji (moc relacji R),
- liczba krotek w jednym bloku (pojemność bloku),
- liczba bloków potrzebnych do zapisania relacji R .

Statystyki dotyczące atrybutu A relacji R :

- liczba różnych wartości przyjmowanych przez atrybut A ,
- minimalna i maksymalna wartość atrybutu A ,
- średnia liczba krotek spełniających warunek równości (selektywność atrybutu A).

Statystyki

Statystyki dotyczące każdej relacji bazowej R :

- liczba krotek relacji (moc relacji R),
- liczba krotek w jednym bloku (pojemność bloku),
- liczba bloków potrzebnych do zapisania relacji R .

Statystyki dotyczące atrybutu A relacji R :

- liczba różnych wartości przyjmowanych przez atrybut A ,
- minimalna i maksymalna wartość atrybutu A ,
- średnia liczba krotek spełniających warunek równości (selektywność atrybutu A).

Statystyki dotyczące indeksów wielopoziomowych:

- liczba poziomów,
- liczba liści.

Selektywność predykatu

Rozważmy relację R oraz operator selekcji σ_p działający na tej relacji.

Selektywnością predykatu p dla relacji R nazywamy wartość

$$\text{sel}_p(R) = \frac{|\sigma_p(R)|}{|R|},$$

czyli stosunek liczności wynikowego zbioru do liczności wejściowej relacji.

Najpierw chcemy wykonać selekcję względem predykatu o najwyższej selektywności.

Selektywność predykatu

Rozważmy relację R oraz operator selekcji σ_p działający na tej relacji.

Selektywnością predykatu p dla relacji R nazywamy wartość

$$\text{sel}_p(R) = \frac{|\sigma_p(R)|}{|R|},$$

czyli stosunek liczności wynikowego zbioru do liczności wejściowej relacji.

Najpierw chcemy wykonać selekcję względem predykatu o najwyższej selektywności.

Przykład. Niech $|R| = 1\,000\,000$, $|\sigma_p(R)| = 1\,000$, $|\sigma_q(R)| = 500\,000$.

Predykat p ma **wysoką** selektywność: $\text{sel}_p(R) = 0,0001$, natomiast selektywność predykatu q jest **niska**: $\text{sel}_q(R) = 0,5$.

Selektywność: złożone predykaty

Rozważmy sytuację, gdy predykat przy operatorze selekcji jest złożony. Wtedy:

- $\text{sel}_{\neg p}(R) = 1 - \text{sel}_p(R)$,
- $\text{sel}_{p \wedge q}(R) = \text{sel}_p(R) \cdot \text{sel}_q(R)$,
- $\text{sel}_{p \vee q}(R) = \text{sel}_p(R) + \text{sel}_q(R) - \text{sel}_p(R) \cdot \text{sel}_q(R)$.

Selektywność: złożone predykaty

Rozważmy sytuację, gdy predykat przy operatorze selekcji jest złożony. Wtedy:

- $\text{sel}_{\neg p}(R) = 1 - \text{sel}_p(R)$,
- $\text{sel}_{p \wedge q}(R) = \text{sel}_p(R) \cdot \text{sel}_q(R)$,
- $\text{sel}_{p \vee q}(R) = \text{sel}_p(R) + \text{sel}_q(R) - \text{sel}_p(R) \cdot \text{sel}_q(R)$.

W drugim i trzecim punkcie zakładamy (poza jednostajnością rozkładu) niezależność predykatów p i q .

Selektywność: złożone predykaty

Rozważmy sytuację, gdy predykat przy operatorze selekcji jest złożony. Wtedy:

- $\text{sel}_{\neg p}(R) = 1 - \text{sel}_p(R)$,
- $\text{sel}_{p \wedge q}(R) = \text{sel}_p(R) \cdot \text{sel}_q(R)$,
- $\text{sel}_{p \vee q}(R) = \text{sel}_p(R) + \text{sel}_q(R) - \text{sel}_p(R) \cdot \text{sel}_q(R)$.


W drugim i trzecim punkcie zakładamy (poza jednostajnością rozkładu) niezależność predykatów p i q .

```
SELECT *  
FROM   studenci  
WHERE  kierunek = 'informatyka analityczna'  
       AND  wynik_matury > 96;
```

Warunki $\text{kierunek} = \text{'informatyka analityczna'}$ oraz $\text{wynik_matury} > 96$ są dodatnio skorelowane, czyli założenie o ich niezależności jest fałszywe.

Histogramy

Jeśli nie chcemy bazować na założeniu o niezależności wartości różnych atrybutów, możemy wykorzystać histogramy.



Powyższy wykres przedstawia ile razy (oś OY) dana wartość (oś OX) interesującego nas atrybutu występuje w krotkach z badanej tabeli.

Jeśli możliwych wartości jest za dużo, możemy pogrupować zbliżone wartości lub opierać się na kwantalach.

Próbkowanie

Niektóre systemy bazodanowe pobierają próbki z tabel, aby na ich podstawie oszacować selektywność.

Jeśli zawartość tabeli ulegnie istotnej zmianie (po wielu operacjach UPDATE, INSERT lub DELETE) próbki są aktualizowane.

Próbkowanie

Niektóre systemy bazodanowe pobierają próbki z tabel, aby na ich podstawie oszacować selektywność.

Jeśli zawartość tabeli ulegnie istotnej zmianie (po wielu operacjach UPDATE, INSERT lub DELETE) próbki są aktualizowane.

	<i>oceny</i>		
	stud_id	kurs_id	ocena
→	1	13	5
	2	10	4
→	3	11	2
	3	12	5
	3	13	4
	4	14	3
→	5	13	2
	5	14	2
	6	10	4

```
SELECT AVG(ocena)
FROM   studenci
WHERE  kurs_id = 13;
```

$$\widehat{\text{sel}}_{\text{kurs_id}=13}(\textit{oceny}) = 2/3$$

Selektywność złączenia

Rozważmy relacje R i Q oraz operator złączenia $\bowtie_{R.x=Q.y}$ na obu relacjach.

Selektywnością złączenia dla relacji R i Q nazywamy wartość

$$\text{sel}_{\bowtie_{R.x=Q.y}}(R, Q) = \frac{|R \bowtie_{R.x=Q.y} Q|}{|R \times Q|},$$

czyli stosunek liczności wynikowego zbioru do maksymalnej potencjalnej liczności.

Selektywność złączenia

Rozważmy relacje R i Q oraz operator złączenia $\bowtie_{R.x=Q.y}$ na obu relacjach.

Selektywnością złączenia dla relacji R i Q nazywamy wartość

$$\text{sel}_{\bowtie_{R.x=Q.y}}(R, Q) = \frac{|R \bowtie_{R.x=Q.y} Q|}{|R \times Q|},$$

czyli stosunek liczności wynikowego zbioru do maksymalnej potencjalnej liczności.

Jeśli mamy wyrażenie algebry relacyjnej zawierające wiele złączeń, możemy je wykonać na wiele sposobów. Na przykład złączenia $(R \bowtie Q) \bowtie S$ oraz $R \bowtie (Q \bowtie S)$ są równoważne.

Selektywność złączenia

Rozważmy relacje R i Q oraz operator złączenia $\bowtie_{R.x=Q.y}$ na obu relacjach.

Selektywnością złączenia dla relacji R i Q nazywamy wartość


$$\text{sel}_{\bowtie_{R.x=Q.y}}(R, Q) = \frac{|R \bowtie_{R.x=Q.y} Q|}{|R \times Q|},$$

czyli stosunek liczności wynikowego zbioru do maksymalnej potencjalnej liczności.

Jeśli mamy wyrażenie algebry relacyjnej zawierające wiele złączeń, możemy je wykonać na wiele sposobów. Na przykład złączenia $(R \bowtie Q) \bowtie S$ oraz $R \bowtie (Q \bowtie S)$ są równoważne.


W takiej sytuacji najpierw realizujemy to złączenie, które ma najwyższą selektywność.

Selektywność złączenia: przykład



W planie nr 1 górne złączenie przetwarza 101,000 krotek, natomiast w planie nr 2 tylko 1,100 krotek.

Programowanie dynamiczne (wersja uproszczona)



R	Q	S	T	najlepszy plan
✓				$i_R(x)$
	✓			$i_Q(y)$
		✓		$i_S(z)$
			✓	$s(T)$


Oznaczenia:

$i_R(x)$ – indeks na atrybucie x w tabeli R

$s(T)$ – skanowanie sekwencyjne tabeli T

HJ – hash join

Programowanie dynamiczne (wersja uproszczona)



R	Q	S	T	najlepszy plan
✓				$i_R(x)$
	✓			$i_Q(y)$
		✓		$i_S(z)$
			✓	$s(T)$
✓	✓			$i_R(x) \text{ HJ } i_Q(y)$
	✓	✓		$i_Q(y) \text{ HJ } i_S(z)$
		✓	✓	$i_S(z) \text{ HJ } s(T)$


Oznaczenia:

$i_R(x)$ – indeks na atrybucie x w tabeli R

$s(T)$ – skanowanie sekwencyjne tabeli T

HJ – hash join

Programowanie dynamiczne (wersja uproszczona)



R	Q	S	T	najlepszy plan
✓				$i_R(x)$
	✓			$i_Q(y)$
		✓		$i_S(z)$
			✓	$s(T)$
✓	✓			$i_R(x) \text{ HJ } i_Q(y)$
	✓	✓		$i_Q(y) \text{ HJ } i_S(z)$
		✓	✓	$i_S(z) \text{ HJ } s(T)$
✓	✓	✓		$(i_R(x) \text{ HJ } i_Q(y)) \text{ HJ } i_S(z)$
	✓	✓	✓	$(i_Q(y) \text{ HJ } i_S(z)) \times s(T)$


Oznaczenia:

$i_R(x)$ – indeks na atrybucie x w tabeli R

$s(T)$ – skanowanie sekwencyjne tabeli T

HJ – hash join

Programowanie dynamiczne (wersja uproszczona)



Oznaczenia:

$i_R(x)$ – indeks na atrybucie x w tabeli R

$s(T)$ – skanowanie sekwencyjne tabeli T

HJ – hash join

R	Q	S	T	najlepszy plan
✓				$i_R(x)$
	✓			$i_Q(y)$
		✓		$i_S(z)$
			✓	$s(T)$
✓	✓			$i_R(x) \text{ HJ } i_Q(y)$
	✓	✓		$i_Q(y) \text{ HJ } i_S(z)$
		✓	✓	$i_S(z) \text{ HJ } s(T)$
✓	✓	✓		$(i_R(x) \text{ HJ } i_Q(y)) \text{ HJ } i_S(z)$
	✓	✓	✓	$(i_Q(y) \text{ HJ } i_S(z)) \times s(T)$
✓	✓	✓	✓	$((i_R(x) \text{ HJ } i_Q(y)) \text{ HJ } i_S(z)) \times s(T)$